Universidade Federal de Minas Gerais
Escola de Engenharia
Curso de Graduação em Engenharia de Sistemas

Desenvolvimento de um Algoritmo Heurístico para Otimização de Leitos Hospitalares

Gustavo Ferreira Tavares

Orientadoras:
Profa. Gabriela Nunes Lopes
Profa. Luiza Bernasdes Real

Belo Horizonte, março de 2026

Capítulo 1

Introdução

Hospitais são instituições fundamentais para a manutenção da saúde pública, enfrentando uma demanda crescente por seus serviços, impulsionada por fatores como o aumento e o envelhecimento populacional [1, 2]. Contudo, essa demanda ocorre em um cenário de alta pressão por eficiência, devido aos custos ascendentes dos serviços de saúde e à limitação de recursos financeiros e físicos [1, 2]. Nesse contexto, a gestão eficiente dos recursos hospitalares não é apenas uma meta operacional, mas uma necessidade estratégica para garantir a sustentabilidade do sistema e a qualidade do atendimento ao paciente [1, 3].

No Brasil, onde o Sistema Único de Saúde (SUS) enfrenta desafios históricos de superlotação e subfinanciamento, a otimização de leitos torna-se ainda mais crucial. Um dos recursos mais críticos e, frequentemente, o gargalo das operações hospitalares, é a disponibilidade de leitos de internação [1, 3]. A gestão ineficiente de leitos gera impactos em cascata por todo o hospital, sendo apontada como uma das principais causas da superlotação nos serviços de emergência, um fenômeno conhecido como bed-block ou "bloqueio de leitos"[1, 3]. Essa superlotação resulta em longos tempos de espera para pacientes admitidos, desvio de ambulâncias para outras unidades e, consequentemente, compromete a segurança e a qualidade do cuidado [1, 3].

A complexidade do problema é acentuada pela natureza estocástica do ambiente hospitalar, marcada pela incerteza nas chegadas de pacientes, especialmente os de emergência, e pela variabilidade no tempo de permanência (LOS - Length of Stay) de cada paciente [4, 3, 2]. Além disso, a alocação de pacientes a leitos transcende uma simples otimização de ocupação. Trata-se de um desafio multiobjetivo que deve conciliar interesses conflitantes de múltiplos stakeholders: pacientes, profissionais da saúde e a administração hospitalar [2].

Do ponto de vista do paciente, busca-se conforto e adequação clínica, como a alocação em quartos com companheiros de faixa etária similar e a minimização de transferências internas [2]. Para os profissionais da saúde, a proximidade geográfica de seus pacientes otimiza as visitas e o tempo de deslocamento, sendo crucial um equilíbrio na carga de trabalho para evitar a sobrecarga e garantir a qualidade da assistência [2]. A administração, por sua vez, visa maximizar a receita e a utilização dos recursos, sem negligenciar objetivos sociais como a equidade no acesso ao tratamento para diferentes perfis de pacientes [5, 6].

Para superar os métodos tradicionais, diversas abordagens de Pesquisa Operacional, como programação matemática, simulação e modelos baseados em teoria das filas, têm sido propostas para enfrentar esse desafio [1, 3]. Métricas como taxa de ocupação, intervalo de substituição entre pacientes (turnaround time) e tempo médio de permanência (length of stay)

são frequentemente utilizadas na literatura para avaliar a eficiência da alocação de leitos [3]. No entanto, o problema de alocação de leitos (PBA - Patient-Bed Allocation ou PAS - Patient Admission Scheduling) é reconhecido por sua alta complexidade computacional, sendo frequentemente classificado como NP-difícil ou NP-completo [4, 6, 2]. Isso significa que encontrar uma solução ótima por meio de métodos exatos (como a programação linear inteira) é, na maioria das vezes, inviável para hospitais de grande porte em tempo hábil [4, 6].

A natureza dinâmica do ambiente hospitalar exige que as decisões de alocação sejam tomadas em tempo real ou quase real, com soluções geradas em segundos, não em horas [6, 2]. Essa lacuna entre a complexidade do problema e a necessidade de respostas rápidas justifica o desenvolvimento de algoritmos heurísticos e meta-heurísticos, capazes de fornecer soluções de alta qualidade e próximas da ótima em um tempo viável [6, 7].

Diante do exposto, o objetivo central deste trabalho é o desenvolvimento de um algoritmo de otimização heurística para o gerenciamento eficiente de leitos hospitalares, modelado como um problema de programação inteira multiobjetivo. O modelo proposto considera variáveis binárias x_i que indicam a ocupação do leito i, e objetiva minimizar simultaneamente a taxa de ocupação média, o intervalo de substituição entre pacientes e o tempo médio de permanência, sujeito a restrições operacionais como limites de ocupação por leito, regras específicas de alocação (ex.: gênero, CID) e tempos mínimos associados a cada possível status do leito (ex.: higienização). A proposta visa criar uma ferramenta de apoio à decisão que opere com rapidez, permitindo sua aplicação em cenários dinâmicos e complexos, típicos de grandes instituições hospitalares.

Capítulo 2

Revisão Bibliográfica

2.1 Gestão de leitos: Problemas similares na literatura

O gerenciamento da capacidade hospitalar e, em particular, a alocação de leitos, pode ser mapeado para diversas famílias clássicas de problemas de otimização documentadas na literatura de Pesquisa Operacional. De acordo com a taxonomia de modelos de otimização detalhada por Talbi [7], o problema de alocação de leitos enquadra-se fortemente na categoria de Otimização Combinatória, compartilhando características fundamentais com os seguintes problemas clássicos:

- **Problemas de Atribuição (*Assignment Problems*):** Em sua essência, alocar pacientes a leitos é uma extensão do Problema de Atribuição Generalizada (GAP) ou do Problema de Atribuição Quadrática (QAP). No QAP, busca-se atribuir um conjunto de objetos a um conjunto de localizações minimizando custos de fluxo e distância [7]. No contexto hospitalar, os "objetos"são os pacientes e as "localizações"são os leitos/quartos, com o custo sendo definido por penalidades de alocação inadequada (ex.: falta de equipamentos) e a "distância"podendo representar o tempo de deslocamento da equipe médica [2].

- **Problemas de Escalonamento (*Scheduling Problems*):** O tempo de permanência do paciente (*Length of Stay* - LOS) insere a dimensão temporal no problema. Brandeau, Sainfort e Pierskalla [1] ressaltam que o planejamento de saúde frequentemente lida com o escalonamento de recursos escassos sob incerteza. Assim, a gestão de leitos assemelha-se ao *Job-Shop Scheduling* [7], onde os pacientes são as "tarefas"(com durações estocásticas) que precisam ser processadas em "máquinas"(leitos), respeitando datas de admissão e alta [6].

- **Problemas de Empacotamento (*Bin Packing*):** A alocação também pode ser vista sob a ótica do *Bin Packing*, onde o objetivo é empacotar itens de diferentes tamanhos no menor número de compartimentos. No hospital, os leitos ou alas hospitalares atuam como compartimentos de capacidade finita e a duração da internação ou a carga de trabalho de enfermagem exigida pelo paciente representa o tamanho do item [8, 7].

Essas similaridades teóricas são essenciais, pois permitem que a vasta gama de algoritmos já desenvolvidos para esses problemas clássicos na ciência da computação seja adaptada ao ambiente da saúde.

2.2 Classificação do problema

Na literatura internacional, o desafio de acomodar pacientes em unidades de internação é frequentemente referido pela sigla PBA (*Patient-Bed Allocation* - Alocação de Pacientes a Leitos) ou PAS (*Patient Admission Scheduling*).

O PBA não é simplesmente atribuir um leito vago a um paciente. Ele envolve uma série de critérios, restrições e objetivos conflitantes que afetam diretamente múltiplos *stakeholders* (pacientes, profissionais da saúde e administração), como:

- **Critérios Clínicos:** Alocar o paciente a um leito na unidade especializada correta (e.g., cardiologia, ortopedia, UTI), garantindo que os equipamentos médicos necessários estejam disponíveis [6, 2].

- **Restrições Operacionais:** Respeitar questões de gênero (leitos masculinos/femininos/mistos), idade (pediatria/geriatria), limites de capacidade do quarto e requisitos de isolamento (para pacientes com doenças infectocontagiosas ou baixa imunidade) [4, 2].

- **Preferências e Conforto:** Tentar alocar pacientes com perfis similares no mesmo quarto (adequação de idade), respeitar a preferência por quartos individuais ou enfermarias e minimizar transferências não planejadas de leito durante a internação, o que causa grande desconforto [6].

- **Eficiência dos Profissionais:** Agrupar pacientes de um mesmo médico ou especialidade para reduzir o tempo de deslocamento durante as visitas (rounds), e balancear a carga de trabalho da equipe de enfermagem, evitando que um único setor concentre todos os pacientes de alta complexidade [2].

- **Eficiência do Sistema:** Maximizar a taxa de ocupação (sem ultrapassar limites seguros), minimizar o tempo de espera ou atraso por um leito (evitando o *bed-block* no pronto-socorro), reduzir o tempo de higienização ou desocupação do leito e acomodar adequadamente pacientes eletivos e de emergência [1, 8].

2.2.1 Complexidade Computacional: O Desafio NP-Difícil

Devido à multiplicidade de variáveis, restrições e à natureza combinatória das alocações possíveis ao longo de um horizonte de tempo, o PBA é classificado na teoria da complexidade computacional como um problema **NP-Difícil** (*NP-Hard*) [4, 6, 2].

O que isso implica, na prática, é que o número de combinações possíveis para alocar P pacientes em L leitos ao longo de D dias cresce de forma exponencial. Segundo a teoria da complexidade detalhada por Talbi [7], para problemas da classe NP-Difícil, não existe nenhum algoritmo exato conhecido capaz de encontrar a solução ótima garantida em tempo polinomial. No contexto de um hospital de grande porte, isso significa que métodos exatos levariam horas, dias ou até semanas de processamento para definir o melhor arranjo de leitos. Contudo, o ambiente hospitalar é altamente dinâmico (com chegadas imprevisíveis de emergências e altas antecipadas/atrasadas), exigindo que as decisões de alocação sejam tomadas quase em tempo real, gerando respostas em segundos [6].

2.2.2 Modelagens na literatura

Diversos trabalhos na literatura tentaram enfrentar o PBA utilizando frameworks matemáticos formais, embora frequentemente esbarrem na barreira da complexidade computacional descrita acima.

As abordagens de **Programação Linear Inteira (PLI)** e **Programação Inteira Mista (MIP)** são as mais comuns na tentativa de modelar o problema de forma exata. Em [6] desenvolveram um modelo matemático rigoroso para o PBA com o objetivo de minimizar as violações de restrições (como transferências e alocações em departamentos errados). Ao tentarem resolver o modelo através de um solver comercial padrão (ILOG CPLEX), não conseguiram encontrar sequer uma solução viável dentro de uma hora de cálculo e, mesmo após uma semana de processamento contínuo, a solução ótima não foi alcançada para instâncias de tamanho real.

Ceschia e Schaerf [4] também modelaram o PBA dinâmico sob incerteza através de Programação Inteira para estabelecer limites inferiores (*lower bounds*). Eles observaram que o modelo completo, mesmo com relaxamentos, exigia tempos proibitivos no CPLEX para instâncias médias e grandes, obrigando-os a fracionar as instâncias.

Para lidar com múltiplos objetivos conflitantes (custo, serviço, satisfação), abordagens de **Programação por Metas (*Goal Programming*)** e funções objetivo ponderadas têm sido amplamente adotadas. Beliën e Demeulemeester [8] formularam o problema de nivelamento da ocupação de leitos gerado pelo centro cirúrgico utilizando Programação Inteira Mista (MIP) e programação quadrática. Da mesma forma, Schäfer et al. [2] formularam uma função de utilidade total, combinando penalidades de médicos, enfermeiros e pacientes. Ressaltam que modelagens analíticas precisas devem ser integradas com lógicas de decisão rápidas para terem valor prático.

2.3 Abordagem proposta

Diante da complexidade combinatória intrínseca ao PBA (característica de problemas NP-Difíceis) e da ineficiência dos métodos exatos (como a Programação Inteira) para fornecer soluções em tempo viável, este trabalho adota a **otimização heurística** como abordagem central.

Conforme sugerido por Talbi [7], quando o tempo disponível para a tomada de decisão é crítico – como no gerenciamento de leitos, onde o fluxo de pacientes no pronto-socorro e no centro cirúrgico não pode parar – o uso de algoritmos aproximados (heurísticas e metaheurísticas) é a via mais adequada. Embora essas técnicas não forneçam garantias matemáticas de que a solução encontrada é o ótimo global, elas exploram o espaço de busca de maneira inteligente e estruturada.

A abordagem heurística destaca-se por possuir um excelente potencial para encontrar soluções de alta qualidade (muito próximas do ótimo) em pouco tempo [4, 6]. Assim, o modelo proposto visa atuar como um sistema de apoio à decisão tática e operacional, oferecendo o melhor balanço entre um alto rigor na satisfação das restrições clínicas/operacionais e o tempo de resposta exigido pela dinâmica do sistema de saúde.

2.4 Meta-heurísticas

Para lidar com a intratabilidade de problemas NP-Difíceis, como a alocação de leitos (PBA), as meta-heurísticas surgem como a principal alternativa aos métodos exatos. O termo "meta-heurística"define uma metodologia de nível superior que atua como uma estratégia guia para projetar heurísticas subjacentes aplicáveis a uma ampla variedade de problemas de otimização [7]. Embora não garantam a otimalidade global, elas fornecem soluções de alta qualidade ("aceitáveis") em um tempo de processamento razoável [7].

O design de qualquer meta-heurística envolve o balanceamento de dois critérios conflitantes: a *exploração* (diversificação), que garante que todas as regiões do espaço de busca sejam visitadas, e a *explotação* (intensificação), que refina as melhores soluções encontradas para gerar resultados ainda melhores [7]. De acordo com suas características de busca, as meta-heurísticas são tipicamente divididas em duas grandes famílias:

- **Meta-heurísticas baseadas em trajetória (S-metaheuristics):** Focam na transformação iterativa de uma única solução, sendo altamente orientadas à explotação (intensificação). A **Busca Tabu (Tabu Search - TS)** utiliza estruturas de memória (listas tabu) para registrar o histórico recente da busca, impedindo que o algoritmo visite soluções recém-avaliadas e fique preso em ótimos locais [7]. Demeester et al. [6] aplicaram um algoritmo de Busca Tabu híbrido para o problema de admissão de pacientes, demonstrando superioridade em relação a métodos exatos em tempo viável. O **Simulated Annealing (SA)**, inspirado no processo de recozimento de metais, utiliza uma função de probabilidade decrescente (temperatura) para aceitar soluções piores no início da busca, evitando ótimos locais e convergindo gradativamente para uma solução refinada [7]. Ceschia e Schaerf [4] utilizaram o SA para modelar e resolver o PAS dinâmico sob incerteza com excelentes resultados.

- **Meta-heurísticas baseadas em população (P-metaheuristics):** Lidam simultaneamente com um conjunto de soluções (população), sendo naturalmente orientadas à exploração (diversificação) do espaço de busca. Os **Algoritmos Genéticos (Genetic Algorithms - GA)** e outras abordagens evolutivas imitam a evolução biológica e a seleção natural, combinando soluções através de operadores de cruzamento (*crossover*) e mutação para gerar novas "descendências"[7, 9]. A **Inteligência de Enxame**, como a Otimização por Nuvem de Partículas (*Particle Swarm Optimization - PSO*) e Otimização por Colônia de Formigas (*Ant Colony Optimization - ACO*), baseia-se no comportamento descentralizado e auto-organizado de animais na natureza [7, 3, 9].

2.5 Combinação de algoritmos

A literatura demonstra que a aplicação de meta-heurísticas puras pode apresentar limitações ao lidar com espaços de busca altamente combinatórios e restritos. A hibridização, ou seja, a combinação de diferentes algoritmos, é uma estratégia adotada para suprir as fraquezas de um método com os pontos fortes de outro [7].

No contexto da saúde e do planejamento de capacidade, diversas abordagens híbridas obtiveram sucesso ao aliar qualidade e velocidade computacional:

- **Híbridos de P-metaheurísticas e S-metaheuristics:** Uma abordagem clássica (conhecida como Algoritmo Memético) incorpora um algoritmo de busca local dentro de um Algoritmo Genético. Enquanto o GA explora globalmente o espaço de soluções por meio da população, a busca local atua como um operador de "mutação inteligente", refinando cada indivíduo e acelerando a convergência para ótimos locais de alta qualidade [7].

- **Híbridos de Meta-heurísticas e Métodos Exatos:** Métodos baseados em Programação Matemática podem ser usados para resolver subproblemas específicos ou inicializar meta-heurísticas. Beliën e Demeulemeester [8] desenvolveram uma abordagem na qual o *Simulated Annealing* é inicializado com uma solução já muito boa, gerada previamente por um modelo de Programação Quadrática, garantindo melhor tempo computacional e qualidade do que o uso de ambos isoladamente.

- **Integração com *Machine Learning*:** Abordagens modernas combinam técnicas de mineração de dados e aprendizado de máquina para guiar a otimização. Schäfer et al. [2] integraram previsões de *Machine Learning* (sobre a chegada de pacientes de emergência) em uma *hiper-heurística*, que por sua vez gerencia heurísticas gulosas subjacentes, resultando em ganhos significativos no gerenciamento operacional dinâmico de leitos.

2.6 Etapa de decisão

Em problemas de saúde, formular e otimizar um modelo matemático é apenas parte do desafio; a fase crítica reside na etapa de tomada de decisão. A tomada de decisão é o processo interativo onde os resultados algorítmicos são avaliados frente a cenários reais, levando à implementação de uma solução prática [7].

No gerenciamento de leitos, a etapa de decisão é de suma importância porque o problema é inerentemente **multiobjetivo** e sujeito a incertezas [2]. Uma otimização estrita baseada apenas em custos ou taxas de ocupação pode negligenciar fatores humanos vitais, como riscos à vida do paciente, carga de trabalho insalubre para enfermeiros ou ineficiência da rotina médica [2]. A etapa de decisão é o momento onde os múltiplos interesses (muitas vezes conflitantes) dos *stakeholders* são balanceados para garantir uma alocação que seja não apenas matematicamente ótima, mas clinicamente e operacionalmente viável.

2.6.1 Tomadores de decisão

Na literatura de otimização multiobjetivo, a interação entre o solucionador (o algoritmo) e o tomador de decisão (gestor hospitalar) pode ocorrer sob três abordagens principais [7]:

- **Abordagem *A Priori*:** O tomador de decisão estabelece suas preferências antes do início da otimização. Isso é frequentemente feito através da agregação das funções objetivo em uma única função de utilidade, onde cada critério recebe um peso. Essa abordagem é computacionalmente rápida (gera uma única solução e requer apenas uma execução da meta-heurística), mas exige que o gestor conheça antecipadamente o comportamento exato e a importância de cada variável [7, 2].

- **Abordagem *A Posteriori*:** O algoritmo executa a busca e devolve um conjunto de soluções de compromisso (a Fronteira de Pareto), representando diferentes cenários otimizados (por exemplo, uma solução excelente para médicos, mas razoável para pacientes; outra excelente para pacientes, mas ruim para enfermagem). Apenas no final o tomador de decisão escolhe a solução desejada. É muito útil quando o cenário não é claro, mas requer alto custo computacional [7].

- **Abordagem Interativa:** Há uma cooperação progressiva entre o gestor e o algoritmo durante a busca. O algoritmo apresenta soluções parciais, o tomador de decisão refina suas preferências, e a busca é redirecionada. É altamente flexível, mas exige envolvimento constante do gestor [7].

2.7 Fechamento da revisão e definição da arquitetura

A gestão de leitos hospitalares foi confirmada ao longo desta revisão como um desafio estocástico, multiobjetivo e de complexidade NP-Difícil, tornando o uso de métodos exatos tradicionalmente inviáveis para decisões em tempo hábil [4, 6, 3].

Diante desse cenário, este trabalho adota os **Algoritmos Genéticos (GA)** como o motor central de otimização global. A escolha pelos GAs justifica-se fortemente por sua natureza baseada em população (*P-metaheuristic*), o que lhes confere a capacidade inerente de explorar o espaço de busca de forma ampla e de gerar, em uma única execução, uma diversidade de soluções candidatas [7]. Além disso, algoritmos genéticos possuem excelente maleabilidade para integrações multiobjetivo e permitem hibridizações com regras clínicas específicas.

Contudo, embora os GAs sejam métodos poderosos para a exploração global (*diversificação*), a literatura aponta que eles frequentemente apresentam limitações na fase de explotação (*intensificação*), ou seja, no ajuste fino das soluções para alcançar ótimos locais de alta qualidade [7]. Para suprir essa lacuna e lidar com o alto nível de restrições do PBA, este trabalho propõe uma arquitetura híbrida, frequentemente denominada **Algoritmo Memético** (classificada como um híbrido de baixo nível, ou *Low-Level Teamwork Hybrid*) [7].

Nesta abordagem, o GA é acoplado a uma meta-heurística de trajetória para a etapa de busca local, sendo a ***Variable Neighborhood Search* (VNS)** a escolha adotada. A integração ocorre substituindo (ou complementando) o operador de mutação cego tradicional do GA por uma chamada ao VNS. Sob uma ótica Lamarckiana [7], o VNS recebe o indivíduo recém-gerado pelo cruzamento, aplica seu processo sistemático de busca em múltiplas vizinhanças para refiná-lo, e devolve o indivíduo otimizado para a população.

A escolha específica do VNS como agente de busca local justifica-se pela topologia restrita do problema de alocação de leitos. Estudos em escalonamento de pacientes, como os conduzidos por Demeester et al. [6] e Ceschia e Schaerf [4], demonstraram que o uso de um único tipo de movimento (ex: apenas trocar pacientes de quarto) é insuficiente para escapar de ótimos locais no ambiente hospitalar. O VNS supera essa barreira ao explorar diferentes estruturas de vizinhança de forma sucessiva e sistemática (por exemplo, alternando entre *Change Room*, *Swap Patients* e transferências parciais) [4, 6]. Assim, a sinergia é maximizada: o GA garante que diferentes bacias de atração do cenário hospitalar sejam descobertas, enquanto o VNS garante que a melhor alocação possível dentro de cada uma dessas bacias seja rapidamente extraída e levada à viabilidade operacional.

Quanto ao tomador de decisão, o modelo assumirá uma postura *a priori* por meio de um sistema de penalidades e funções de utilidade estruturadas. Em um ambiente operacional hospitalar diário, a equipe de admissão precisa de respostas dinâmicas em frações de segundo, inviabilizando análises complexas *a posteriori* para cada novo paciente. Os pesos das restrições e interesses dos *stakeholders* serão pré-parametrizados [2], permitindo que o algoritmo recomende a alocação de forma rápida, determinística e autônoma na ponta da operação.

Com a base teórica acerca das características estruturais do problema estabelecida e a arquitetura híbrida (GA + VNS) definida, o próximo capítulo detalhará a metodologia. Nesse capítulo, será apresentada a modelagem matemática adotada para a instituição de saúde em estudo, bem como o design das vizinhanças e a implementação computacional do Algoritmo Memético proposto para solucionar esse complexo desafio.

Capítulo 3

Metodologia

Esta seção visa apresentar e discutir a metodologia utilizada para modelar e implementar o problema de otimização inteira da gestão de leitos hospitalares. Dessa forma, primeiramente é mostrado o panorama geral do desafio, para depois apresentar a modelagem matemática proposta e possíveis simplificações e, por fim, a arquitetura de sua implementação computacional baseada em um Algoritmo Memético.

3.1 Descrição do problema

O Problema de Alocação de Leitos (PBA) abordado neste trabalho concentra-se no nível operacional e tático da gestão hospitalar. O objetivo diário da equipe de admissão é alocar um conjunto de pacientes, com diferentes necessidades clínicas e tempos de permanência, a um conjunto finito de quartos e leitos disponíveis nas diversas alas do hospital [6]. A alocação deve garantir a viabilidade clínica e, simultaneamente, maximizar o conforto do paciente e a eficiência dos recursos operacionais [2].

3.1.1 Parâmetros, variáveis e discretização do tempo

Para reduzir a complexidade computacional e refletir a rotina de censos hospitalares, o tempo é discretizado e modelado em dias consecutivos [4, 6]. O dia atua como a menor unidade indivisível de tempo do sistema. Dessa forma, as internações, altas e transferências ocorrem estritamente na transição de um dia para o outro [6].

O sistema recebe como entrada uma lista de pacientes que possuem uma data de admissão e uma data de alta prevista, resultando em um Tempo de Permanência (LOS - *Length of Stay*) ininterrupto [4]. Durante todo o LOS estipulado, o paciente deve obrigatoriamente permanecer alocado nas dependências do hospital, não sendo consideradas transferências para unidades externas.

O hospital é subdividido em departamentos, que contêm quartos com capacidades variadas (número máximo de leitos). Como não há diferenciação de equipamentos vitais ou infraestrutura entre leitos de um mesmo quarto, os leitos tornam-se indistinguíveis. Conforme proposto por Ceschia e Schaerf [4], o problema pode ser simplificado passando de uma alocação baseada em leitos individuais para uma alocação direta em quartos, o que reduz substancialmente o espaço de busca. Assim, as variáveis de decisão centrais definem em qual quarto o paciente passará cada dia do seu período de internação.

3.1.2 Restrições

O problema está sujeito a dois conjuntos de regras [4, 6]:

- **Restrições Rígidas (*Hard Constraints*):** Devem ser obrigatoriamente satisfeitas para que a solução seja viável. Incluem:
  - *Garantia de Internação Contínua:* Todo paciente admitido deve ter um leito garantido durante todos os dias do seu tempo de permanência, sem sair do hospital.
  - *Capacidade do Quarto:* O número de pacientes alocados simultaneamente em um quarto não pode exceder a capacidade máxima (número de leitos) daquele quarto.
  - *Gênero e Idade:* Quartos compartilhados não podem abrigar pacientes de gêneros distintos simultaneamente (a menos que a política da ala permita) e devem respeitar as faixas etárias do departamento (ex.: pediatria).
- **Restrições Flexíveis (*Soft Constraints*):** Representam preferências que, se violadas, geram penalidades, mas não inviabilizam a solução. Incluem:
  - *Transferências:* Evitar que um paciente mude de quarto de um dia para o outro durante sua internação.
  - *Preferência de Acomodação:* Respeitar o desejo do paciente pelo tamanho do quarto (ex.: quarto individual vs. enfermaria).
  - *Especialidade Desejável:* Alocar o paciente no departamento ideal para a sua patologia.

3.1.3 Pesos e Abordagem Multiobjetivo

A natureza multiobjetivo do PBA exige o balanceamento de interesses conflitantes (ex.: minimizar transferências vs. agrupar pacientes da mesma especialidade). Conforme discutido na fundamentação teórica, este trabalho adota uma abordagem *a priori* [7]. Todos os objetivos e violações de restrições flexíveis são agregados em uma única função de utilidade através do Método das Somas Ponderadas [2, 6]. Dessa forma, pesos específicos (W) são atribuídos a cada violação, refletindo as prioridades da administração hospitalar. Quanto maior o peso de um critério (como a penalidade por transferências), maior será o esforço do algoritmo para evitá-lo.

3.1.4 Dados e Instâncias de Teste

Para testar e validar o algoritmo proposto, a literatura aponta a dificuldade de obtenção de dados hospitalares reais abertos devido a questões de sigilo médico [6]. Diante disso, e com o objetivo de isolar e avaliar estritamente a performance computacional e a qualidade da otimização das heurísticas aplicadas, este trabalho opta pela utilização de **dados fixos e determinísticos**.

Conforme a metodologia validada por Schäfer et al. [2], a eliminação dos fatores estocásticos (como variações inesperadas no tempo de permanência ou cancelamentos repentinos)

durante a fase de validação algorítmica permite monitorar com clareza a eficácia da metaheurística. Dessa forma, as taxas de chegada, as capacidades dos quartos e os tempos de internação serão predefinidos e fornecidos ao modelo como parâmetros exatos.

Para garantir a representatividade clínica, os parâmetros que compõem essas instâncias fixas (como a proporção entre pacientes, a distribuição das faixas etárias e a capacidade de cada departamento) poderão ser inspirados nas instâncias de *benchmarks* públicos amplamente utilizados pela comunidade científica para o PBA, como os *datasets* disponibilizados originamente por Demeester et al. [6] e adaptados por Ceschia e Schaerf [4].

3.2 Modelagem Matemática

A formulação a seguir define o Problema de Alocação de Leitos (PBA) em sua totalidade matemática como um modelo de Programação Linear Inteira (PLI). Esta modelagem exata estabelece o rigor analítico do problema e permite a validação do modelo através de *solvers* comerciais em instâncias de menor porte.

A formulação adota a abordagem de linearização proposta por Ceschia e Schaerf [5] para rastrear as características dinâmicas de convivência nos quartos (como a política de isolamento de gêneros), introduzindo variáveis auxiliares que definem o estado de ocupação de cada quarto a cada dia.

3.2.1 Conjuntos e Parâmetros

O modelo é fundamentado nos seguintes conjuntos, índices e parâmetros:

- P: Conjunto de todos os pacientes. Este conjunto é subdividido em pacientes do sexo feminino (P_F) e masculino (P_M), de modo que $P = P_F \cup P_M$.
- R: Conjunto de quartos disponíveis no hospital.
- D: Conjunto de dias que compõem o horizonte de planejamento.
- $D_p \subseteq D$: Subconjunto de dias contínuos em que o paciente p está internado.
- c_r: Capacidade máxima (número de leitos) do quarto r.
- $C_{p,r}$: Custo de alocação do paciente p ao quarto r. Este parâmetro penaliza alocações indesejadas, devido a inadequação da especialidade clínica do departamento ao diagnóstico do paciente [5].
- W_{transf}: Peso de penalidade atribuído a cada transferência de quarto sofrida pelo paciente durante a internação.
- W_{gen}: Peso de penalidade por violação da política de gênero (alocar pacientes de sexos distintos no mesmo quarto no mesmo dia).

3.2.2 Variáveis de Decisão

O modelo baseia-se em variáveis primárias para a alocação e variáveis auxiliares para a linearização dos custos [5].

Variáveis Principais (Alocação e Transferência):

$$x_{p,r,d} \in \{0,1\} \quad \text{Vale 1 se o paciente } p \text{ está alocado no quarto } r \text{ no dia } d. \tag{3.1}$$

$$t_{p,r,d} \in \{0,1\} \quad \text{Vale 1 se o paciente } p \text{ é transferido do quarto } r \text{ do dia } d \text{ para o dia } d+1. \tag{3.2}$$

Variáveis de Linearização (Status do Quarto): Para rastrear a mistura de gêneros de forma linear, definem-se as variáveis de status do quarto r no dia d:

$$f_{r,d} \in \{0,1\} \quad \text{Vale 1 se há pelo menos uma paciente mulher no quarto } r \text{ no dia } d. \tag{3.3}$$

$$m_{r,d} \in \{0,1\} \quad \text{Vale 1 se há pelo menos um paciente homem no quarto } r \text{ no dia } d. \tag{3.4}$$

$$b_{r,d} \in \{0,1\} \quad \text{Vale 1 se o quarto } r \text{ no dia } d \text{ possui pacientes de ambos os gêneros.} \tag{3.5}$$

3.2.3 Função Objetivo

A função objetivo Z visa minimizar a soma total das penalidades. Ela é composta pelos custos clínicos da alocação ($C_{p,r}$), pelas penalidades aplicadas a cada transferência de leito realizada (W_{transf}) e pelas penalidades geradas pelo uso de quartos mistos (W_{gen}):

$$\min Z = \sum_{p\in P}\sum_{r\in R}\sum_{d\in D_p}(C_{p,r}\cdot x_{p,r,d}) + \sum_{p\in P}\sum_{r\in R}\sum_{d\in D_p}(W_{transf}\cdot t_{p,r,d}) + \sum_{r\in R}\sum_{d\in D}(W_{gen}\cdot b_{r,d}) \tag{3.6}$$

3.2.4 Restrições

O modelo está sujeito às seguintes restrições:

1. Atribuição Única e Contínua: Cada paciente p deve estar alocado a exatamente um quarto durante todos os dias contínuos da sua internação (D_p).

$$\sum_{r\in R} x_{p,r,d} = 1, \quad \forall p \in P, \forall d \in D_p \tag{3.7}$$

2. Limite de Capacidade do Quarto: O número total de pacientes acomodados simultaneamente em um quarto r no dia d não pode exceder sua capacidade máxima c_r.

$$\sum_{p\in P} x_{p,r,d} \leq c_r, \quad \forall r \in R, \forall d \in D \tag{3.8}$$

3. Rastreamento de Transferências: A variável de transferência deve ser ativada caso o paciente ocupe o quarto r no dia d, mas não esteja mais alocado nele no dia subsequente $d+1$ da sua internação [5].

$$t_{p,r,d} \geq x_{p,r,d} - x_{p,r,d+1}, \quad \forall p \in P, \forall r \in R, \forall d \in D_p \setminus \{\text{dia da alta}\} \tag{3.9}$$

4. Identificação de Presença Feminina: Se uma paciente do conjunto feminino (P_F) for alocada ao quarto r no dia d, a flag indicadora de presença feminina daquele quarto deve ser ativada.

$$f_{r,d} \geq x_{p,r,d}, \quad \forall p \in P_F, \forall r \in R, \forall d \in D \tag{3.10}$$

5. Identificação de Presença Masculina: Semelhantemente à restrição anterior, a flag deve ser ativada para pacientes do conjunto masculino (P_M).

$$m_{r,d} \geq x_{p,r,d}, \quad \forall p \in P_M, \forall r \in R, \forall d \in D \tag{3.11}$$

6. Detecção de Mistura de Gêneros (Quarto Misto): Esta restrição força a variável $b_{r,d}$ a assumir o valor 1 caso o quarto possua representantes de ambos os gêneros no mesmo dia, acionando a penalidade W_{gen} na função objetivo [5].

$$b_{r,d} \geq m_{r,d} + f_{r,d} - 1, \quad \forall r \in R, \forall d \in D \tag{3.12}$$

3.2.5 Domínio das Variáveis

Conforme definido anteriormente, o domínio de todas as variáveis restringe-se a valores binários:

$$x_{p,r,d}, t_{p,r,d}, f_{r,d}, m_{r,d}, b_{r,d} \in \{0, 1\} \tag{3.13}$$

3.3 Representação da solução

Um dos passos mais críticos no design de qualquer meta-heurística, especialmente em Algoritmos Genéticos (GA), é a escolha de uma representação de solução (cromossomo) que seja ao mesmo tempo eficiente em termos de memória e fácil de ser manipulada pelos operadores de busca [7].

Para o Problema de Alocação de Leitos (PBA), a representação computacional de um indivíduo na população precisa espelhar a variável de decisão $x_{p,r,d}$. Em vez de utilizar uma matriz tridimensional esparsa, que consumiria processamento excessivo, a solução é representada como um *array* (ou dicionário de dados), onde cada índice representa um paciente $p \in P$. O valor (alelo) contido nesse índice é um subvetor que lista o quarto $r \in R$ ocupado pelo paciente em cada dia contínuo $d \in D_p$ do seu tempo de permanência (LOS) [6, 4].

Solução Inicial:

Em algoritmos genéticos e de busca local, a qualidade da população inicial impacta diretamente a velocidade de convergência. Para garantir que as restrições rígidas (como a garantia de internação ininterrupta sem sair do hospital) sejam respeitadas desde o início, a geração da solução inicial ocorre de forma semigulosa e aleatória [4]. Para cada paciente na lista de admissão, o algoritmo tenta alocá-lo a um quarto aleatório que suporte sua faixa etária e restrições clínicas, mantendo-o no mesmo quarto do primeiro ao último dia de sua internação ($t_{p,r,d} = 0$). Limites de capacidade (c_r) são tratados na avaliação: caso a capacidade de um quarto seja excedida na solução inicial, a função objetivo penaliza o indivíduo (refletindo a superlotação), forçando o GA a corrigir essa sobrecarga ao longo das gerações por meio das pressões de seleção evolutiva [4, 6].

Estruturas de vizinhança

Na arquitetura do Algoritmo Memético adotada, após a geração de novos indivíduos pelos operadores de cruzamento do GA, a *Variable Neighborhood Search* (VNS) é aplicada como um mecanismo de busca local intensiva. Para que o VNS consiga escapar de ótimos locais em um ambiente altamente restrito como o de um hospital, ele deve alternar sistematicamente entre diferentes topologias de vizinhança [7].

Baseando-se nas abordagens consolidadas por Ceschia e Schaerf [4] e Demeester [6], para o agendamento dinâmico de pacientes em quartos, as seguintes estruturas de vizinhança formam o núcleo do otimizador local:

- N_1**: Mudança de Quarto (*Change Room - CR*):** Este movimento consiste em transferir virtualmente um paciente p de seu quarto atual para um novo quarto r' durante **toda** a sua estadia. Trata-se de uma exploração primária do espaço de busca (S_0), mantendo o número de transferências intrahospitalares igual a zero, mas buscando quartos que reduzam o custo estático $C_{p,r}$ [4, 6].

- N_2**: Troca entre Pacientes (*Swap Patients - SP*):** Consiste em permutar os quartos atribuídos a dois pacientes distintos p_1 e p_2, cujos dias de internação possuam alguma sobreposição. Esse movimento é vital pois, frequentemente, a mudança de um paciente isolado (N_1) é inviabilizada por limites de capacidade. A troca simultânea permite que o algoritmo contorne bloqueios de leitos e acomode melhor os pacientes sem inflar a ocupação máxima do quarto [4, 6].

- N_3**: Mudança Parcial de Quarto (*Partial Change Room - PCR*):** As vizinhanças anteriores exploram apenas soluções sem transferências. No entanto, quartos ideais podem estar disponíveis apenas em parte do período de internação. O movimento PCR atua no espaço de soluções expandido (S_1) ao selecionar um dia d no meio da internação de um paciente p e alterar seu quarto apenas daquele dia em diante. Embora esse movimento ative a variável de transferência $t_{p,r,d}$ e adicione a penalidade de transferência (W_{transf}) à Função Objetivo, ele confere a flexibilidade necessária para resolver gargalos de capacidade em dias de pico [4].

O VNS iterará sequencialmente sobre essas três vizinhanças ($N_1 \rightarrow N_2 \rightarrow N_3$). Caso o movimento em N_1 não melhore a função objetivo, a busca expande para a permutação de pacientes (N_2). Se o ótimo local persistir, a flexibilização através de transferências (N_3) é explorada. Qualquer melhoria em N_2 ou N_3 faz com que a busca retorne imediatamente para a vizinhança mais simples N_1, reiniciando o ciclo de refinamento da alocação até que não haja mais ganhos marginais.

3.4 Implementação

Avaliação Procedural e Simplificação do Modelo

Embora a Seção 3.2 apresente a formulação matemática exata e completa do problema por meio de Programação Linear Inteira (PLI) — necessária para a validação em solvers comerciais como o Gurobi — a implementação computacional da meta-heurística pode adotar uma abordagem mais enxuta para a avaliação da função objetivo [6].

Em modelos estritamente lineares, a detecção de penalidades dinâmicas, como a violação da política de gênero no mesmo quarto, exige a criação de múltiplas variáveis de decisão auxiliares (e.g., $f_{r,d}$, $m_{r,d}$ e $b_{r,d}$) e restrições de amarração para cada quarto e cada dia do horizonte de planejamento [5]. Para um hospital de grande porte, isso resulta em uma explosão combinatória do número de variáveis, tornando o modelo intratável em tempo hábil [6].

Na arquitetura do Algoritmo Memético implementada neste trabalho (em Python), contorna-se essa limitação através da **avaliação procedural**. Como a meta-heurística explora o espaço de busca gerando arranjos completos (ou vizinhanças) a cada iteração, o algoritmo possui conhecimento total e imediato sobre o estado de ocupação de qualquer quarto r no dia d.

Dessa forma, a heurística dispensa totalmente a declaração e o rastreamento das variáveis auxiliares de linearização na memória. O custo dinâmico de convivência é calculado proceduralmente sob demanda: ao avaliar a inserção de um paciente em um quarto, o algoritmo simplesmente itera sobre a lista dos atuais ocupantes daquele quarto e aplica lógicas condicionais (*if/else*) para aplicar penalidades de gênero ou calcular diferenças de idade (*age mixing*) [2].

Essa diferença fundamental entre a modelagem exata (focada em restrições algébricas) e a modelagem heurística (focada em estruturas de dados e rotinas de código) é o que permite ao VNS e ao GA avaliarem milhares de soluções candidatas em frações de segundo, garantindo a viabilidade da ferramenta para o uso operacional diário.

Ferramentas e Ambiente de Desenvolvimento

O algoritmo heurístico proposto, bem como a modelagem de dados e rotinas de avaliação, estão sendo desenvolvidos na linguagem de programação **Python**. Línguagem escolhida por sua vasta biblioteca padrão e pelo rico ecossistema focado em análise de dados e otimização, permitindo uma prototipagem rápida e eficiente dos algoritmos.

Para o controle de versionamento e armazenamento do código-fonte, utiliza-se a ferramenta Git, com o projeto hospedado publicamente na plataforma **GitHub**. O repositório oficial do trabalho pode ser acessado através do **link**.

O ambiente de desenvolvimento foi estruturado seguindo boas práticas de engenharia de software para garantir a reprodutibilidade dos experimentos. A execução do projeto é isolada através de um ambiente virtual (`venv`), com todas as dependências bibliotecárias e suas respectivas versões documentadas no arquivo `requirements.txt`. A arquitetura do código está modularizada no diretório `src`, onde o script `main.py` atua como o orquestrador principal da otimização, interligando a fonte de dados, a avaliação da função objetivo e os operadores do Algoritmo Memético (GA e VNS).

3.5 Métricas para avaliação de desempenho

A avaliação de desempenho de algoritmos heurísticos exige um planejamento experimental rigoroso para comprovar sua eficácia e eficiência frente ao problema proposto. Conforme definido por Talbi [7], para a análise de algoritmos de otimização, o desempenho do Algoritmo Memético desenvolvido será medido sob três perspectivas principais: qualidade da solução, eficiência computacional e robustez estatística.

- **Eficácia (Qualidade da Solução):** A qualidade das alocações geradas será avaliada primariamente pelo valor final alcançado na função objetivo Z (Equação 3.6). Como

o problema de alocação de leitos é de minimização, valores menores indicarão um melhor balanceamento das restrições flexíveis. Adicionalmente, métricas operacionais explícitas serão extraídas, como o número absoluto de transferências realizadas durante a internação e a taxa de ocupação dos quartos.

Para atestar rigorosamente a eficácia do método, as soluções heurísticas serão comparadas com resultados matemáticos exatos obtidos através do *solver* comercial Gurobi:

- *Em instâncias de pequeno porte:* Sem alterações ao modelo matemático, o Gurobi será utilizado para encontrar a solução ótima global do problema. A eficácia da meta-heurística será medida pela sua capacidade de igualar ou se aproximar desse valor ótimo global.
- *Em instâncias de médio e grande porte:* Devido à explosão combinatória que inviabiliza a obtenção da solução ótima exata em tempo hábil, os resultados heurísticos serão comparados a Limites Inferiores (*Lower Bounds*). Estes limites serão calculados pelo Gurobi a partir da **relaxação linear** do modelo matemático (permitindo que as variáveis binárias assumam valores contínuos fracionários), uma abordagem de validação abordada por Ceschia e Schaerf [5].

- **Eficiência Computacional:** Considerando que a alocação de leitos exige tomada de decisão dinâmica na rotina de admissão hospitalar, o tempo de execução é uma métrica crítica [6]. Será medido o tempo de CPU (em segundos) necessário para que o algoritmo atinja a sua condição de parada. O algoritmo também será avaliado pela sua velocidade de convergência, ou seja, o número de iterações ou gerações necessárias até que a melhor solução seja encontrada.

- **Análise Estatística e Robustez:** Devido à natureza estocástica dos Algoritmos Genéticos e à aleatoriedade na exploração de vizinhanças da *Variable Neighborhood Search* (VNS), uma única execução não é suficiente para atestar a qualidade do método [7]. Cada cenário de teste será executado múltiplas vezes (e.g., 30 rodadas independentes com sementes aleatórias distintas). Serão reportados o melhor valor (*Best*), a média (*Average*) e o desvio padrão das execuções. Para a visualização da dispersão dos resultados, serão utilizados gráficos do tipo *Boxplot*. Caso ocorram comparações com outras configurações ou algoritmos, testes estatísticos não-paramétricos (como o teste de Wilcoxon) serão aplicados para comprovar a significância das melhorias alcançadas [6].

3.6 Plano de desenvolvimento do TCC II

A continuidade desta proposta no Trabalho de Conclusão de Curso II (TCC II) focará na fase prática de implementação, análise de dados e consolidação dos resultados obtidos pelo modelo proposto. O desenvolvimento será estruturado em seis etapas sequenciais, detalhadas a seguir:

1. **Definição e Geração das Instâncias de Teste:** Criação dos cenários fixos de teste (arquivos de configuração) contendo diferentes tamanhos de carga de pacientes, de modo a simular variações na demanda e na capacidade dos quartos hospitalares.

2. **Conclusão da Implementação Computacional:** Finalização da codificação do algoritmo memético em Python, integrando as lógicas de avaliação do Algoritmo Genético com as estruturas de vizinhança propostas no VNS.

3. **Calibração de Parâmetros (Tuning):** Realização de testes preliminares para definir os melhores parâmetros para a meta-heurística, tais como o tamanho da população, taxas de mutação e cruzamento, critérios de parada e os pesos associados à função de utilidade.

4. **Execução dos Experimentos:** Execução das rodadas sistemáticas do algoritmo para todas as instâncias de teste, realizando a coleta automática das métricas de desempenho previamente estabelecidas na Seção 3.5.

5. **Análise dos Resultados:** Tabulação dos dados, geração dos gráficos e comparação técnica da performance do modelo quanto ao tempo computacional e a otimização dos recursos hospitalares.

6. **Redação Final:** Escrita dos capítulos de Resultados e Conclusão, bem como a revisão geral do documento para a submissão e defesa da tese.

O fluxo de trabalho supracitado está resumido visualmente no fluxograma da Figura 3.1.

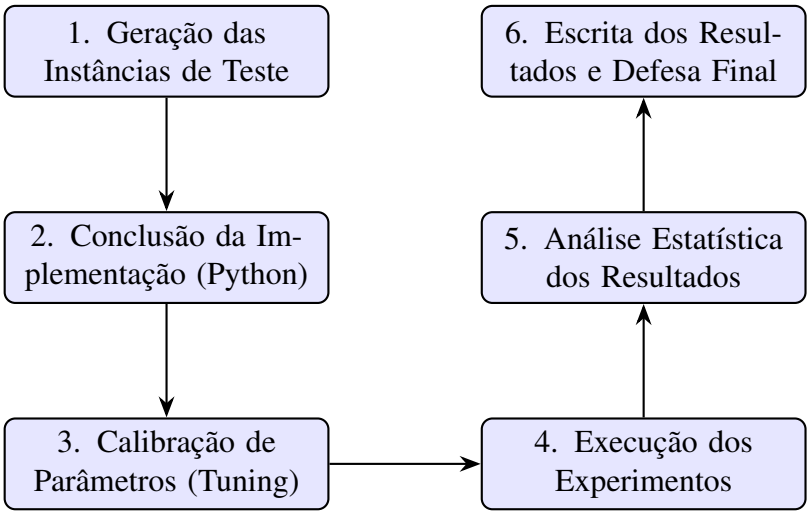


Figura 3.1: Fluxograma das etapas de execução previstas para o TCC II.

Referências Bibliográficas

[1] BRANDEAU, M. L.; SAINFORT, F.; PIERSKALLA, W. P. *Operations research and health care: a handbook of methods and applications*. [S.l.]: Springer Science & Business Media, 2004. v. 70.

[2] SCHÄFER, F. et al. Combining machine learning and optimization for the operational patient-bed assignment problem. *Health Care Management Science*, v. 26, n. 4, p. 785, 2023.

[3] HE, L. et al. A systematic review of research design and modeling techniques in inpatient bed management. *Computers & Industrial Engineering*, Elsevier, v. 127, p. 451–466, 2019.

[4] CESCHIA, S.; SCHAERF, A. Modeling and solving the dynamic patient admission scheduling problem under uncertainty. *Artificial intelligence in medicine*, Elsevier, v. 56, n. 3, p. 199–205, 2012.

[5] CESCHIA, S.; SCHAERF, A. Local search and lower bounds for the patient admission scheduling problem. *Computers & Operations Research*, Elsevier, v. 38, n. 10, p. 1452–1463, 2011.

[6] DEMEESTER, P. et al. A hybrid tabu search algorithm for automatically assigning patients to beds. *Artificial Intelligence in Medicine*, Elsevier, v. 48, n. 1, p. 61–70, 2010.

[7] TALBI, E.-G. *Metaheuristics: from design to implementation*. [S.l.]: John Wiley & Sons, 2009.

[8] BELIËN, J.; DEMEULEMEESTER, E. Building cyclic master surgery schedules with leveled resulting bed occupancy. *European journal of operational research*, Elsevier, v. 176, n. 2, p. 1185–1204, 2007.

[9] ALA, A.; CHEN, F. Appointment scheduling problem in complexity systems of the healthcare services: A comprehensive review. *Journal of Healthcare Engineering*, Wiley Online Library, v. 2022, n. 1, p. 5819813, 2022.

[10] VISSERS, J. M.; ADAN, I. J.; DELLAERT, N. P. Developing a platform for comparison of hospital admission systems: An illustration. *European Journal of Operational Research*, Elsevier, v. 180, n. 3, p. 1290–1301, 2007.